Relatório de evolução — ChargeGrid Assistant (Sprint 4)

FIAP · Prompt and Artificial Intelligence · EV Challenge 2026 × GoodWe · Equipe 03 · Turma 1CCPK · 23/10/2026

1. Resumo da evolução

- **Sprint 1:** planejamento (persona do motorista de EV, escopo, fluxograma, system prompt e modelo de teste).
- **Sprint 2:** chatbot em Python puro (Colab + Gemini 2.5 Flash) com prompt e dados de sessão fixos.
- **Sprint 3:** refactory em LangChain LCEL (memória, saída estruturada Pydantic, guardrails, prompt versionado, eval de 16 casos).
- **Sprint 4:** RAG com ChromaDB + nomic-embed-text sobre 7 documentos, grounding com citação de fonte verificável, defesa em camadas contra injeção, avaliação por iteração com juiz tipo RAGAS, interface Gradio e comparação de modelos.

2. Pipeline RAG: decisões e trade-offs

Escopo. O assistente atende o motorista de veículo elétrico em eletropostos comerciais da rede ChargeGrid (Problema 3 do estudo: experiência do usuário comprometida). O cenário condominial (EV ChargeOps) e os regimentos condominiais de carregamento compartilhado ficaram fora da base por decisão de escopo da equipe, mantendo a persona e o contexto comercial definidos na Sprint 1; perguntas sobre esse assunto caem na recusa fora do contexto.

- **Base:** manual e datasheet reais do HCA G2 + 5 documentos fictícios da operação do totem (CG-01 a CG-05), catalogados com tipo e público; conteúdo de instalação nunca chega ao motorista; o PDF do manual não é publicado (direitos autorais).
- **Chunking:** RecursiveCharacterTextSplitter 800/120 (15%); por página nos reais (citação com página exata) e **por seção** nos fictícios (um assunto por chunk).
- **Embeddings:** nomic-embed-text **local** (a nuvem não oferece embeddings na nossa conta) com prefixos search_query/search_document; ChromaDB persistente, cosseno.
- **Busca:** filtro de metadados por público e **cota por camada** (3 fictícios + 2 reais), pois o manual tem 78% dos chunks.
- **Geração:** prompt versionado (v1, v2), JSON validado (encontrou_na_base, resposta, fontes, escalar_suporte), porta de distância 0,40, validação das fontes citadas.

3. Comparativo antes × depois (obrigatório)

Métrica	Sprints 1/2 (versão original) [it0_sem_rag_ref]	Sprint 4 (RAG avaliado) [it7_candidata]
Fidelidade (0–1): afirmações sustentadas pelo contexto	0,220	0,968
Relevância da resposta (0–1)	0,731	0,749
Presença de citação de fonte	0,000 (0%)	1,000
Citação correta (fonte aceitável)	-	0,958
Qualidade do contexto recuperado: hit@k	- (sem busca)	1,000
Qualidade do contexto recuperado: MRR	- (sem busca)	0,839
Alucinação em fatos proibidos (menor = melhor)	0,333	0,000
Comportamento correto (recusas, escopo, injeção)	- (sem guardrails)	0,954
Tokens de prompt por turno	221	2462
Latência média por turno (s)	1,43	0,83

O 'antes' mede o chatbot das Sprints 1/2 contra os mesmos documentos como contexto de referência; métricas sem sentido para ele (recusas, busca) aparecem como '-'.

4. Scores por iteração (mesmo eval set de 43 casos)

Iteração	Comport.	hit@k	MRR	Cit. correta	Fidel.	Relev.	Recusa indevida	Tokens	Lat. (s)
it0_sem_rag	-	0,636	0,553	-	0,192	0,746	-	221	1,19
it0_sem_rag_ref	-	1,000	0,839	-	0,220	0,731	-	221	1,43
it0_prompt_v1	0,837	0,636	0,553	0,809	0,863	0,773	0,273	2367	2,12
it0_baseline	0,837	0,636	0,553	0,800	0,909	0,778	0,273	2468	1,10
it1_limpeza	0,814	0,591	0,538	0,842	0,917	0,766	0,318	2445	1,55
it2_secao	0,884	0,818	0,724	0,909	0,907	0,761	0,136	2244	0,82
it3_prefixo	0,907	0,818	0,784	0,957	0,934	0,740	0,136	2330	0,80
it4_camadas	0,954	1,000	0,839	0,960	0,896	0,741	0,045	2467	1,79
it5_limiar	0,954	1,000	0,839	0,960	0,933	0,749	0,045	2462	0,79
it6_sem_limpeza	0,977	1,000	0,842	1,000	0,884	0,737	0,045	2489	0,85
it7_candidata	0,954	1,000	0,839	0,958	0,968	0,749	0,091	2462	0,83

Rubrica: fidelidade = afirmações sustentadas ÷ totais; relevância = cosseno médio entre 3 perguntas geradas a partir da resposta e a pergunta original (evasiva = 0). Diferenças de 1 caso valem 0,023–0,045 e a fidelidade varia ~0,04 entre execuções: só ganhos maiores que isso foram considerados.

5. Segurança

Obediência do LLM sozinho a documentos envenenados, com repetições: prompt v1: obedeceu 0/40 (IC95% -0,00–0,09); prompt v2: obedeceu 0/40 (IC95% -0,00–0,09). Camadas: heurística de pergunta e de documento → escape de tags → prompt v2 → validação de fontes e canário → filtro de saída.

6. Problemas encontrados e soluções

- **Embeddings indisponíveis no Ollama Cloud.** O diagnóstico mostrou que a conta não enxerga nenhum modelo de embedding na nuvem (o endpoint /api/embed devolveu 401 para todos), embora o chat funcione. *Solução:* O mesmo `nomic-embed-text` (único modelo aprovado) passou a rodar em um Ollama local; o chat segue na nuvem. A decisão ficou em `config.OLLAMA_EMBED_BASE_URL`.
- **Injeção de prompt por documento.** No teste real de 19/10 o gpt-oss obedeceu a uma instrução sutil escondida em um documento e ainda o citou como fonte. *Solução:* Defesa em camadas: heurística de documentos, prompt v2, escape de tags XML, validação das fontes citadas, canário e filtro de saída (links, e-mails, imagens).
- **Falso positivo do guardrail da Sprint 3.** A pergunta legítima de tarifação (hp-03) era recusada como fora de escopo pelo regex de domínio. *Solução:* Novas âncoras de domínio e troca do bloqueio de 'fora do domínio' pela porta de distância; a moderação ganhou padrões de 'novo papel' (0 falsos positivos em 72 perguntas legítimas).
- **Recuperação fraca na linha de base.** Chunks com vários assuntos diluíam o embedding e o manual (78% dos chunks) espremia as respostas da operação do totem. *Solução:* Chunking por seção, prefixos do nomic e busca por camada (cota para documentos fictícios e reais). Ver a tabela de iterações.
- **Erros na própria avaliação.** A relevância comparava consulta com documento (prefixos assimétricos do nomic) e o 'antes' sem RAG reportava métricas artificiais. *Solução:* Relevância simétrica (`--recalcular` corrige resultados gravados), métricas não comparáveis do 'antes' viraram '-' e tudo foi registrado na rubrica (seção 7).
- **Raciocínio do gpt-oss consome o orçamento de tokens.** Com 40 tokens a resposta veio vazia (o modelo gastou tudo 'pensando'). *Solução:* `NUM_PREDICT_RAG = 800` e `reasoning = low` para modelos gpt-oss; a cadeia diagnostica resposta vazia e o experimento M6 mede a perda com 300 tokens.

7. Equipe e divisão de trabalho

Nome	RM	Tarefa principal
Wendel Pedro Rezende	573126	Desenvolvimento e execução da Sprint 4: pipeline RAG, guardrails, avaliação por iteração, interface Gradio e relatórios (com apoio de IA generativa)
Arthur Araujo Massarioli	573308	Auxílio na T3
Daniel Alejandro Pupo Martinez	573075	Auxílio da T3-T9
Victor Hugo Lavaqui	573838	Auxílio na T7