Relatório de evolução — ChargeGrid Assistant (Sprint 4)

FIAP · Prompt and Artificial Intelligence · EV Challenge 2026 × GoodWe · Equipe 03 · Turma 1CCPK · 22/10/2026

1. Resumo da evolução

- **Sprint 1:** planejamento (persona do motorista de EV, escopo, fluxograma, system prompt e modelo de teste).
- **Sprint 2:** chatbot em Python puro (Colab + Gemini 2.5 Flash) com prompt e dados de sessão fixos.
- **Sprint 3:** refactory em LangChain LCEL (memória, saída estruturada Pydantic, guardrails, prompt versionado, eval de 16 casos).
- **Sprint 4:** RAG com ChromaDB + nomic-embed-text sobre 7 documentos, grounding com citação de fonte verificável, defesa em camadas contra injeção, avaliação por iteração com juiz tipo RAGAS, interface Gradio e comparação de modelos.

2. Pipeline RAG: decisões e trade-offs

- **Base:** manual e datasheet reais do HCA G2 + 5 documentos fictícios da operação do totem (CG-01 a CG-05), catalogados com tipo e público; conteúdo de instalação nunca chega ao motorista; o PDF do manual não é publicado (direitos autorais).
- **Chunking:** RecursiveCharacterTextSplitter 800/120 (15%); por página nos reais (citação com página exata) e **por seção** nos fictícios (um assunto por chunk).
- **Embeddings:** nomic-embed-text **local** (a nuvem não oferece embeddings na nossa conta) com prefixos search_query/search_document; ChromaDB persistente, cosseno.
- **Busca:** filtro de metadados por público e **cota por camada** (3 fictícios + 2 reais), pois o manual tem 78% dos chunks.
- **Geração:** prompt versionado (v1, v2), JSON validado (encontrou_na_base, resposta, fontes, escalar_suporte), porta de distância 0,40, validação das fontes citadas.

3. Comparativo antes × depois (obrigatório)

Métrica	Sprints 1/2 (versão original) [it0_sem_rag]	Sprint 4 (RAG avaliado) [it4_camadas]
Fidelidade (0–1): afirmações sustentadas pelo contexto	0,192	0,896
Relevância da resposta (0–1)	0,746	0,697
Presença de citação de fonte	0,000 (0%)	1,000
Citação correta (fonte aceitável)	-	0,960
Qualidade do contexto recuperado: hit@k	- (sem busca)	1,000
Qualidade do contexto recuperado: MRR	- (sem busca)	0,839
Alucinação em fatos proibidos (menor = melhor)	0,333	0,000
Comportamento correto (recusas, escopo, injeção)	- (sem guardrails)	0,954
Tokens de prompt por turno	221	2467
Latência média por turno (s)	1,19	1,79

O 'antes' mede o chatbot das Sprints 1/2 contra os mesmos documentos como contexto de referência; métricas sem sentido para ele (recusas, busca) aparecem como '-'.

4. Scores por iteração (mesmo eval set de 43 casos)

Iteração	Comport.	hit@k	MRR	Cit. correta	Fidel.	Relev.	Recusa indevida	Tokens	Lat. (s)
it0_sem_rag	-	0,636	0,553	-	0,192	0,746	-	221	1,19
it0_prompt_v1	0,837	0,636	0,553	0,809	0,863	0,773	0,273	2367	2,12
it0_baseline	0,837	0,636	0,553	0,800	0,909	0,778	0,273	2468	1,10
it1_limpeza	0,814	0,591	0,538	0,842	0,917	0,766	0,318	2445	1,55
it2_secao	0,884	0,818	0,724	0,909	0,907	0,761	0,136	2244	0,82
it3_prefixo	0,907	0,818	0,784	0,957	0,934	0,698	0,136	2330	0,80
it4_camadas	0,954	1,000	0,839	0,960	0,896	0,697	0,045	2467	1,79
it5_limiar	0,954	1,000	0,839	0,960	0,933	0,702	0,045	2462	0,79

Rubrica: fidelidade = afirmações sustentadas ÷ totais; relevância = cosseno médio entre 3 perguntas geradas a partir da resposta e a pergunta original (evasiva = 0). Diferenças de 1 caso valem 0,023–0,045 e a fidelidade varia ~0,04 entre execuções: só ganhos maiores que isso foram considerados.

5. Segurança

Nas execuções do eval set, a obediência do LLM sozinho a documentos envenenados foi 0,000 (4 ataques, 1 execução cada). Para uma taxa com intervalo de confiança: `python -m evals.avaliar_rag --medir-injecao 10 --prompt-versao v2`. Camadas: heurística de pergunta e de documento → escape de tags → prompt v2 → validação de fontes e canário → filtro de saída.

6. Problemas encontrados e soluções

- **Embeddings indisponíveis no Ollama Cloud.** O diagnóstico mostrou que a conta não enxerga nenhum modelo de embedding na nuvem (o endpoint /api/embed devolveu 401 para todos), embora o chat funcione. *Solução:* O mesmo `nomic-embed-text` (único modelo aprovado) passou a rodar em um Ollama local; o chat segue na nuvem. A decisão ficou em `config.OLLAMA_EMBED_BASE_URL`.
- **Injeção de prompt por documento.** No teste real de 19/10 o gpt-oss obedeceu a uma instrução sutil escondida em um documento e ainda o citou como fonte. *Solução:* Defesa em camadas: heurística de documentos, prompt v2, escape de tags XML, validação das fontes citadas, canário e filtro de saída (links, e-mails, imagens).
- **Falso positivo do guardrail da Sprint 3.** A pergunta legítima de tarifação (hp-03) era recusada como fora de escopo pelo regex de domínio. *Solução:* Novas âncoras de domínio e troca do bloqueio de 'fora do domínio' pela porta de distância; a moderação ganhou padrões de 'novo papel' (0 falsos positivos em 72 perguntas legítimas).
- **Recuperação fraca na linha de base.** Chunks com vários assuntos diluíam o embedding e o manual (78% dos chunks) espremia as respostas da operação do totem. *Solução:* Chunking por seção, prefixos do nomic e busca por camada (cota para documentos fictícios e reais). Ver a tabela de iterações.
- **Erros na própria avaliação.** A relevância comparava consulta com documento (prefixos assimétricos do nomic) e o 'antes' sem RAG reportava métricas artificiais. *Solução:* Relevância simétrica (`--recalcular` corrige resultados gravados), métricas não comparáveis do 'antes' viraram '-' e tudo foi registrado na rubrica (seção 7).
- **Raciocínio do gpt-oss consome o orçamento de tokens.** Com 40 tokens a resposta veio vazia (o modelo gastou tudo 'pensando'). *Solução:* `NUM_PREDICT_RAG = 800` e `reasoning = low` para modelos gpt-oss; a cadeia diagnostica resposta vazia e o experimento M6 mede a perda com 300 tokens.

7. Equipe e divisão de trabalho

Nome	RM	Tarefa principal
Wendel Pedro Rezende	573126	Desenvolvimento e execução da Sprint 4: pipeline RAG, guardrails, avaliação por iteração, interface Gradio e relatórios (com apoio de IA generativa)
Arthur Araujo Massarioli	573308	(a preencher pela equipe)
Daniel Alejandro Pupo Martinez	573075	(a preencher pela equipe)
Victor Hugo Lavaqui	573838	(a preencher pela equipe)